

02&%V92!
A(&YI8V4
@9&%Y(0`

[RElog] Ukrywanie danych (string'ów) wewnątrz pliku wykonywalnego ([sheadovas/artykuly/relog/relog-ukrywanie-danych-stringow-wewnatrz-pliku-wykonywalnego/](https://sheadovas.pl/artykuly/relog/relog-ukrywanie-danych-stringow-wewnatrz-pliku-wykonywalnego/))

Kwi 08, 2016 / [RElog \(sheadovas/category/artykuly/relog/\)](https://sheadovas.pl/category/artykuly/relog/)

Kilka słów o uniemożliwieniu wyciągnięciu np. hasła do bazy danych, z której korzysta program.

Założmy, że posiadamy napisaliśmy program, który z jakiegoś powodu musi posiadać jakieś wrażliwe dane (np login i hasło do bazy danych) zapisane „na sztywno” w kodzie.

Jak łatwo zdać sobie sprawę takie dane domyślnie nie są w żaden chronione i są potencjalnie wystawione na atak. W tym wpisie chciałbym się skupić na kilku potencjalnych rozwiązaniach tego problemu.

Przykładowy kod

Dla pełnego zrozumienia problemu poniżej przedstawiam uproszczony program, którego celem jest „połączenie się” z bazą danych.

Przykładowy programC++

```
1 #include <string>
2 #include <iostream>
3
4 void connect()
5 {
6     std::string username = "my_username";
7     std::string password = "my_password";
8
9     // "połączenie"
10    std::cout << username << ' ' << password << "\n";
11 }
12
13
14 int main()
15 {
16     connect();
17 }
```

Jak widzimy dane do logowania trzymamy jako zwykły string, przekonajmy się dlaczego nie jest to dobry pomysł:

```
$ strings my_program
1 | ...
2 | my_username
3 | my_password
4 | ...
```

Jak widzimy już takie proste narzędzie jak *strings* umożliwia znalezienie nam stringów przechowujących nasz login i hasło z wnętrza pliku wykonywalnego.

Rozwiązania problemu

Poniżej chciałbym przedstawić kilka potencjalnych rozwiązań problemu, które intuicyjnie przychodzą do głowy

1. Zasyfrowanie danych.
2. Zaciemnienie sekcji danych i kodu.
3. Wymuszenie podania loginu i hasła w trakcie działania programu
4. Usunięcie bezpośredniego łączenia z bazą danych, komunikacja z bazą danych tylko przez serwer.

Dwa ostatnie rozwiązania są potencjalnie najbezpieczniejsze, a to dlatego że zakładają zrzucenie odpowiedzialności weryfikacji danych na serwer, wrażliwych danych nie ma w pliku wykonywalnym.

Jednakże nie zawsze możemy zastosować to rozwiązanie, a to dlatego że tymi danymi nie zawsze są dane służące do logowania, a np kod wykonujący jakiś sprytny algorytm, dodajmy że program w takim przypadku może pracować w trybie offline.

1. Szyfrowanie

Szyfrowanie jest rzeczą, która nasuwa się na samym początku jednakże należy pamiętać, że skoro nasz program jest w stanie dane odszyfrować, to postronna osoba po chwili analizy będzie w stanie zrozumieć nasz program i cały proces odwrócić.

Załóżmy że zaszyfrowaliśmy dane do logowania i proces odszyfrowania odbywa się w 100% po stronie programu chwilę przed logowaniem, założmy że teraz nie byliśmy w stanie znaleźć loginu i hasła narzędziem strings ponieważ te dane niczym się nie różniły od innych śmieci.

Spójrzmy na fragment kodu odpowiedzialnego za łączenie z bazą danych (dla zwiększenia czytelności wynik z *Hoppera*):

```
(gdb) disas connect
1 0000000000400f72      mov     rbp, rsp
2 0000000000400f75      push    rbx
3 0000000000400f76      sub     rsp, 0x78
4 0000000000400f7a      lea     rax, qword [ss:rbp+var_20]
5 0000000000400f7e      mov     rdi, rax
6 0000000000400f81      call    j__ZNSaIcEC1Ev
7 0000000000400f86      lea     rdx, qword [ss:rbp+var_20]
8 0000000000400f8a      lea     rax, qword [ss:rbp+var_80]
9 0000000000400f8e      mov     esi, 0x401319
10 0000000000400f93     mov     rdi, rax
11 0000000000400f96     call    j__ZNSsC1EPKcRKSaIcE
12 0000000000400f9b     lea     rax, qword [ss:rbp+var_20]
13 0000000000400f9f     mov     rdi, rax
14 0000000000400fa2     call    j__ZNSaIcED1Ev
15 0000000000400fa7     lea     rax, qword [ss:rbp+var_20]
16 0000000000400fab     mov     rdi, rax
17 0000000000400fae     call    j__ZNSaIcEC1Ev
18 0000000000400fb3     lea     rdx, qword [ss:rbp+var_20]
19 0000000000400fb7     lea     rax, qword [ss:rbp+var_70]
20 0000000000400fbb     mov     esi, 0x401325                ; "EYsBq__[C@N"
21 0000000000400fc0     mov     rdi, rax
22 0000000000400fc3     call    j__ZNSsC1EPKcRKSaIcE
23 0000000000400fc8     lea     rax, qword [ss:rbp+var_20]
24 0000000000400fcc     mov     rdi, rax
25 0000000000400fcf     call    j__ZNSaIcED1Ev
26 0000000000400fd4     lea     rdx, qword [ss:rbp+var_80]
27 0000000000400fd8     lea     rax, qword [ss:rbp+var_60]
28 0000000000400fdc     mov     rsi, rdx
29 0000000000400fdf     mov     rdi, rax
30 0000000000400fe2     call    j__ZNSsC1ERKSs
31 0000000000400fe7     lea     rax, qword [ss:rbp+var_50]
32 0000000000400feb     lea     rdx, qword [ss:rbp+var_60]
33 0000000000400fef     mov     rsi, rdx
```

Po chwili analizy jesteśmy w stanie stwierdzić, że:

- username = „EYs]_M@DqEM”
- password = „EYsBq__[C@N”

Zauważamy również call’e do funkcji o nazwie „_Z7decryptSs”, sama nazwa łudzaco przypomina wyrażenie „decrypt”, a więc spróbujmy się w niej zanurzyć aby zrozumieć jak działa.

```
(gdb) disas decrypt
```

```
1 Dump of assembler code for function _Z7decryptSs:
2 0x0000000000400c24 <+0>: push    rbp
3 0x0000000000400c25 <+1>: mov     rbp, rsp
4 0x0000000000400c28 <+4>: push    rbx
5 0x0000000000400c29 <+5>: sub     rsp, 0x28
6 0x0000000000400c2d <+9>: mov     QWORD PTR [rbp-0x28], rdi
7 0x0000000000400c31 <+13>: mov     QWORD PTR [rbp-0x30], rsi
8 0x0000000000400c35 <+17>: lea     rax, [rbp-0x15]
9 0x0000000000400c39 <+21>: mov     rdi, rax
10 0x0000000000400c3c <+24>: call    0x400a20 <_ZNSaIcEC1Ev@plt>
11 0x0000000000400c41 <+29>: lea     rdx, [rbp-0x15]
12 0x0000000000400c45 <+33>: mov     rax, QWORD PTR [rbp-0x28]
13 0x0000000000400c49 <+37>: mov     esi, 0x401318
14 0x0000000000400c4e <+42>: mov     rdi, rax
15 0x0000000000400c51 <+45>: call    0x4009d0 <_ZNSsC1EPKcRKSaIcE@plt>
16 0x0000000000400c56 <+50>: lea     rax, [rbp-0x15]
17 0x0000000000400c5a <+54>: mov     rdi, rax
18 0x0000000000400c5d <+57>: call    0x400a00 <_ZNSaIcED1Ev@plt>
19 0x0000000000400c62 <+62>: mov     DWORD PTR [rbp-0x14], 0x0
20 0x0000000000400c69 <+69>: jmp     0x400c9e <_Z7decryptSs+122>
21 0x0000000000400c6b <+71>: mov     eax, DWORD PTR [rbp-0x14]
22 0x0000000000400c6e <+74>: movsxd  rdx, eax
23 0x0000000000400c71 <+77>: mov     rax, QWORD PTR [rbp-0x30]
24 0x0000000000400c75 <+81>: mov     rsi, rdx
25 0x0000000000400c78 <+84>: mov     rdi, rax
26 0x0000000000400c7b <+87>: call    0x4009e0 <_ZNSsixEm@plt>
27 0x0000000000400c80 <+92>: movzx   eax, BYTE PTR [rax]
28 0x0000000000400c83 <+95>: xor     eax, 0x2f
29 0x0000000000400c86 <+98>: add     eax, 0x3
30 0x0000000000400c89 <+101>: movsx   edx, al
31 0x0000000000400c8c <+104>: mov     rax, QWORD PTR [rbp-0x28]
32 0x0000000000400c90 <+108>: mov     esi, edx
33 0x0000000000400c92 <+110>: mov     rdi, rax
```

To co tutaj widzimy to stworzenie pustego obiektu klasy std::string oraz pętlę przechodzącą po całym stringu. Daruję sobie całą analizę i skupmy się na właściwym fragmencie „szyfrującym”:

```
Szyfrowanie
1 0000000000400c80      movzx     eax, byte [ds:rax]
2 0000000000400c83      xor       eax, 0x2f
3 0000000000400c86      add       eax, 0x3
```

Mamy tutaj wrzucenie poszczególnego znówu do rejestru eax, następnie zostaje on xorowany z wartością 47 (0x2f), po czym zostanie dodana liczba 3 (0x3)

Jak łatwo się domyślić cały proces jest bardzo łatwo odwrócić operacją odwrotną dla xor jest xor, a dla dodawania odejmowanie (w razie gdybyśmy chcieli odwrócić cały proces), napiszmy sobie mały program, którego zadaniem jest deszyfrowanie:

```
decrypt
1 std::string decrypt(std::string word)
2 {
3     std::string a="";
4     for(int i=0;i<word.size();++i)
5     {
6         a += (word[i] ^ 47) + 3;
7     }
8
9     return a;
10 }
```

Jak się przekonamy, to jest kalka tego co widzieliśmy w postaci kodu maszynowego, otrzymane dane zgadzają się z tym co znaleźliśmy wcześniej (my_username:my_password). Szyfrowanie mogło wyglądać w ten sposób:

```
1 std::string encrypt(std::string word)
2 {
3     std::string a = "";
4     for(int i=0;i<word.size();++i)
5     {
6         a += (word[i] - 3) ^ 47;
7     }
8     return a;
9 }
```

Jak widzimy nie tylko poznaliśmy zaszyfrowane login i hasło, ale zdołaliśmy także ten proces odwrócić!

Zazwyczaj wystarczy nam jedynie znalezienie sposobu na poznanie odszyfrowanego loginu i hasła (równie dobrze mogliśmy też śledzić w debuggerze proces deszyfrowania i w ten sposób te dane wyciągnąć), największą słabością tego sposobu jest to, że kod maszynowy jest czytelny i w większości przypadków po odpowiednio długiej analizie powinniśmy być w stanie go odtworzyć.

2. Obfuskacja

Wikipedia:

Zaciemnianie kodu (także obfuskacja, z ang. obfuscation) to technika przekształcania programów, która zachowuje ich semantykę, ale znacząco utrudnia zrozumienie

Obfuskacja kodu

Jednym ze sposobów zaciemnienie kodu jest wykorzystanie faktu, że instrukcja MOV jest kompletna z punktu widzenia Maszyny Turinga[1] (polecam zajrzeć do tego dokumentu) to możliwe jest zastąpienie wielu innych instrukcji używając wyłącznie instrukcji MOV. Co to oznacza? Otóż dla (nie tylko) przeciętnego reversera znacznie prostsza jest analiza kodu generowanego normalnie przez kompilator. Przykładowo poniżej widzimy zrzut funkcji main wyświetlającej „Super Secret String” (standardowe opcje gcc).

```
objdump
1 000000000040052d <main>:
2   40052d: 55          push    %rbp
3   40052e: 48 89 e5    mov     %rsp,%rbp
4   400531: bf d4 05 40 00    mov     $0x4005d4,%edi
5   400536: e8 d5 fe ff ff    callq   400410 <puts@plt>
6   40053b: b8 00 00 00 00    mov     $0x0,%eax
7   400540: 5d          pop     %rbp
8   400541: c3          retq
9   400542: 66 2e 0f 1f 84 00 00    nopw    %cs:0x0(%rax,%rax,1)
10  400549: 00 00 00
11  40054c: 0f 1f 40 00    nopl    0x0(%rax)
```

Poniżej widzimy fragment robiący dokładnie to samo, skompilowany domyślnymi opcjami movcc

```
objdump
```

1	08048744	<main>:			
2	8048744:	a1 e8 33 3f 08	mov	0x83f33e8,%eax	
3	8048749:	ba 44 87 04 88	mov	\$0x88048744,%edx	
4	804874e:	a3 70 32 1f 08	mov	%eax,0x81f3270	
5	8048753:	89 15 74 32 1f 08	mov	%edx,0x81f3274	
6	8048759:	b8 00 00 00 00	mov	\$0x0,%eax	
7	804875e:	b9 00 00 00 00	mov	\$0x0,%ecx	
8	8048763:	ba 00 00 00 00	mov	\$0x0,%edx	
9	8048768:	a0 70 32 1f 08	mov	0x81f3270,%al	
10	804876d:	8b 0c 85 80 d8 04 08	mov	0x804d880(,%eax,4),%ecx	
11	8048774:	8a 15 74 32 1f 08	mov	0x81f3274,%dl	
12	804877a:	8a 14 11	mov	(%ecx,%edx,1),%dl	
13	804877d:	89 15 60 32 1f 08	mov	%edx,0x81f3260	
14	8048783:	a0 71 32 1f 08	mov	0x81f3271,%al	
15	8048788:	8b 0c 85 80 d8 04 08	mov	0x804d880(,%eax,4),%ecx	
16	804878f:	8a 15 75 32 1f 08	mov	0x81f3275,%dl	
17	8048795:	8a 14 11	mov	(%ecx,%edx,1),%dl	
18	8048798:	89 15 64 32 1f 08	mov	%edx,0x81f3264	
19	804879e:	a0 72 32 1f 08	mov	0x81f3272,%al	
20	80487a3:	8b 0c 85 80 d8 04 08	mov	0x804d880(,%eax,4),%ecx	
21	80487aa:	8a 15 76 32 1f 08	mov	0x81f3276,%dl	
22	80487b0:	8a 14 11	mov	(%ecx,%edx,1),%dl	
23	80487b3:	89 15 68 32 1f 08	mov	%edx,0x81f3268	
24	80487b9:	a0 73 32 1f 08	mov	0x81f3273,%al	
25	80487be:	8b 0c 85 80 d8 04 08	mov	0x804d880(,%eax,4),%ecx	
26	80487c5:	8a 15 77 32 1f 08	mov	0x81f3277,%dl	
27	80487cb:	8a 14 11	mov	(%ecx,%edx,1),%dl	
28	80487ce:	89 15 6c 32 1f 08	mov	%edx,0x81f326c	
29	80487d4:	a1 60 32 1f 08	mov	0x81f3260,%eax	
30	80487d9:	8b 15 64 32 1f 08	mov	0x81f3264,%edx	
31	80487df:	8b 04 85 20 a3 04 08	mov	0x804a320(,%eax,4),%eax	
32	80487e6:	8b 04 90	mov	(%eax,%edx,4),%eax	
33	80487e9:	a3 60 32 1f 08	mov	%eax,0x81f3260	

W tym momencie ręczna analiza robi się momentalnie mało przyjemna. Jeżeli kod wykonywałby np. jakieś szyfrowanie to nam byłoby niezwykle trudno zrozumieć ten algorytm analizując wyłącznie jego kod maszynowy.

W powyższych listingach użyłem [movfuscator’a (<https://github.com/xoreaxeaxeax/movfuscator>)]. Narzędzia tego typu mają swoje ograniczenia (np. *movfuscator* nie ukrywa stringów, ale w tym przypadku można zastosować np system obfuskacji stringów[2]), ale w przypadku zaciemnienia jedynie fragmentów odpowiadających za jakieś magiczne obliczenia powinien się nadać i niewątpliwie wydłuży przynajmniej w nieznacznym stopniu poznanie wszystkich tajników naszego kodu o czym już wspomniałem.

VM

Innym potencjalnym sposobem na jeszcze dodatkowe zaciemnienie kodu jest utworzenie maszyny wirtualnej, która obsługiwałaby naszą własną składnię języka maszynowego. Całkiem sporo opowiedział o tym [Gynvael Coldwind (<https://www.youtube.com/watch?v=wROV20w6Nt0>)], w skrócie chodzi o to aby ściśle tajny program był napisany w naszym własnym języku, następnie my taki wygenerowany bajt-kod przekazujemy do naszego normalnego programu, z kolei on uruchomi maszynę wirtualną, a na niej wykona nasz algorytm.

W takim przypadku aby zrozumieć algorytm to należy najpierw zrozumieć jak działa maszyna wirtualna -> napisać disassembler -> (teraz można) zrozumieć algorytm, w dodatku przy tego typu obfuskacji nikt nie mówi, że sama składnia musi być „przyjazna”, co pokazali *Gyn* i *j00ru*, a rozbił na części pierwsze [pakt (<https://gdtr.wordpress.com/2011/06/24/solving-pimp-crackme-by-j00ru-and-gynvael-coldwind/>)].

Podsumowanie

Jak widać istnieje wiele sposobów na utrudnienie pracy reverserowi, jeżeli możemy to powinniśmy zrzucić część którą chcemy chronić od wystawienia na widok np. na serwer, który jedynie zwróci wynik.

Chciałbym też zwrócić uwagę, że ten temat został opisany przeze mnie jedynie pobieżnie (nie poruszyłem np. tematu packerów) i na pewno nie został wyczerpany, zachęcam do samodzielnego zgłębienia tematu i zajrzenia do m.in. „Materiałów dodatkowych”.

Materiały dodatkowe

- [1][„mov is Turing complete” (<https://www.cl.cam.ac.uk/~sd601/papers/mov.pdf>)]
- [2][Przykładowy system obfuskacji stringów (<http://www.codeproject.com/Articles/502283/Strings-Obfuscation-System>)]
- [3][Dissect || PE (<http://research.dissect.pe/docs/blackhat2012-paper.pdf>)]

Code ON!